26 de Febrero 2026

IES Azarquiel
Curso de Especialización en Inteligencia Artificial y Big Data

Sistema de Análisis del Mercado de Automoción

Asignatura: Sistemas de Big Data y Sistemas de Aprendizaje Automático

Profesor: Sebastián Rubio Valero

Alumnos: Nicolás Cabello Alonso

Índice de contenidos:

Fase 1. Selección y Comprensión del dominio....3
1.1 Análisis Exploratorio del Dominio.... 3
2. Preprocesamiento y limpieza....8
2.1 Integración de Múltiples Fuentes....8
2.2 Limpieza y Tratamiento de Valores Anómalos....9
4. Minería de Datos.... 10
4.1 Árbol de Decisión para Predecir el Valor Residual.... 10
4.2 Regresión Múltiple para Precios — Random Forest....11
4.3 Análisis de Sentimiento en Reviews usando Naive Bayes....12
4.4 K-NN y SVM para Detectar Anomalías en los Precios.... 14
4.5 Reseñas Contradictorias.... 16
4.6 Predicción del Precio de Venta....17
5. Ejercicios Prácticos....20
5.1 Clasificación de Segmento de Mercado.... 20
5.2 Sistema de Recomendación de Vehículos.... 21
Conclusiones.... 25

Fase 1. Selección y Comprensión del dominio

1.1 Análisis Exploratorio del Dominio

Comenzaremos realizando un análisis exploratorio de datos (EDA) sobre distintos conjuntos de datos relacionados con vehículos, con el fin de comprender las características técnicas de los automóviles y su relación con variables como el precio, el consumo y las emisiones.

El análisis busca identificar patrones, relaciones entre variables y posibles factores que influyen en el valor de los vehículos, proporcionando una base para futuros modelos predictivos o toma de decisiones.

En esta fase inicial, hemos procedido a la carga e inspección de tres fuentes de datos principales:

- **Vehículos (vehiculos.json)**: Contiene información técnica de 300 vehículos, incluyendo marca, modelo, potencia (CV), tipo de combustible y segmento.
- **Ventas y Mantenimiento (ventas_mantenimiento.csv)**: Un registro de 600 operaciones con detalles sobre el precio real de venta, kilometraje, costes de mantenimiento e incidencias mecánicas.
- **Opiniones (opiniones_clientes.xml)**: 500 reseñas de clientes que valoran aspectos como confort, seguridad y fiabilidad en una escala de 0 a 5.

Análisis de marcas,modelos y segmentos

Al cargar el vehiculos.json y mirar las gráficas, nos hemos dado cuenta de varias cosas:

- **Segmentos**: Los datos están muy cargados hacia los Compactos (102 unidades) y los **SUV** (86 unidades). Esto es lógico, ya que son los coches que más volumen de ventas mueven. Los segmentos Deportivo y Ejecutivo son mucho más escasos.
- **Marcas**: Tenemos un total de 12 marcas. Tras analizar las frecuencias, vemos que Peugeot, Hyundai y Kia son las más repetidas, lo que nos da un perfil de mercado de gama media-estándar.

Identificación de relaciones entre características técnicas y precios

Buscando qué variables afectan más en el coste de los vehículos, hemos sacado varias conclusiones clave:

- **Relación potencia-precio**: Existe una conexión directa entre potencia_cv y precio_base. A medida que suben los caballos, el precio de salida del vehículo aumenta de forma constante.
- **Eficiencia**: Los vehículos con menores emisiones_co2 y consumo_urbano suelen estar vinculados a modelos más recientes que presentan un precio_base más elevado.

Patrones de ventas y mantenimiento

En esta sección analizamos cómo se distribuye el negocio y qué factores técnicos están mermando el valor de los vehículos.

Distribución por región del vendedor

En la gráfica de distribución por región se observa que Andalucía y Valencia presentan el mayor volumen de ventas, seguidas por País Vasco y Madrid, mientras que Cataluña presenta menor número de ventas.

- **Andalucía** y la **Comunidad Valenciana** pueden tener más ventas de automóviles que la Comunidad de Madrid, Cataluña y el País Vasco principalmente por su mayor peso poblacional (especialmente Andalucía), su gran extensión territorial y la mayor dependencia del vehículo privado en zonas rurales y costeras.

- Además, ambas regiones tienen una fuerte actividad turística, lo que impulsa la compra y renovación de vehículos de alquiler. En cambio, en Madrid y Barcelona el transporte público desarrollado y las restricciones medioambientales reducen en parte la necesidad de adquirir coche propio.

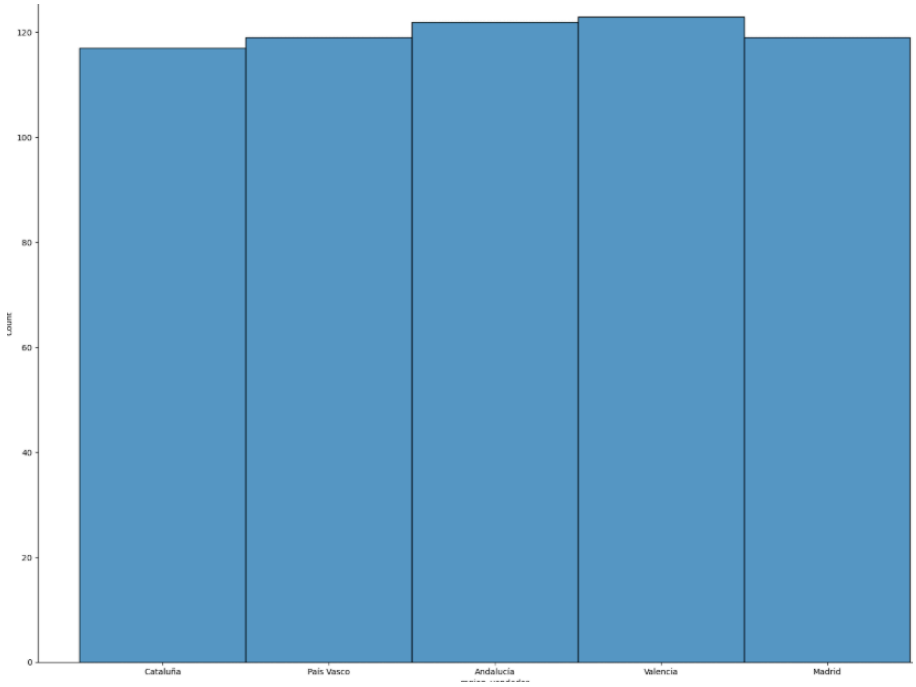

Análisis de ventas según la fecha

Como podemos observar en la gráfica se han vendido más coches en mayo del año 2023 seguido de julio y septiembre de 2023, esto puede ser debido a estrategias comerciales, renovación de inventario y el gasto producido en la campaña navideña ya que enero es el mes con menos ventas debido a ese gasto realizado antes.

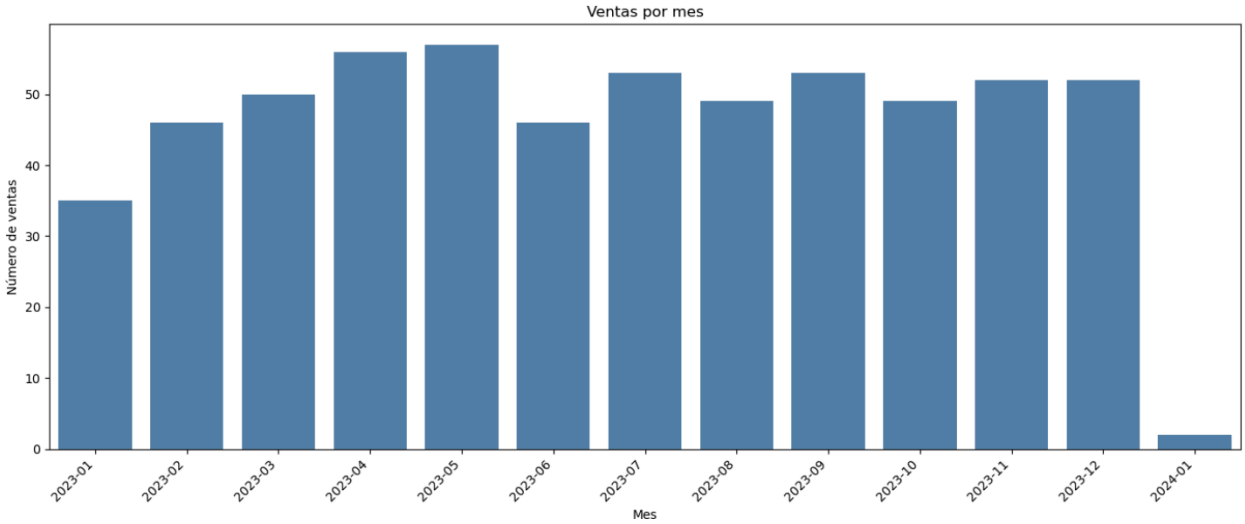

Mapa de correlaciones entre ventas y mantenimiento

A partir de la matriz de correlación, se pueden extraer varias conclusiones importantes sobre los patrones de ventas y mantenimiento. En primer lugar, se observa que el precio de venta real tiene una correlación fuerte y positiva (0,78) con el coste de mantenimiento anual. Esto indica que los vehículos más caros tienden a requerir mayores gastos de mantenimiento.

Por otro lado, variables como la región, el kilometraje de venta, los servicios realizados y las incidencias mecánicas presentan correlaciones muy bajas con el valor residual estimado, lo que sugiere que estas características no influyen de manera significativa en el patrón general de ventas. Esto implica que factores como la ubicación del cliente o el historial de uso del vehículo tienen un impacto limitado en la predicción de ventas y en la planificación de mantenimiento.

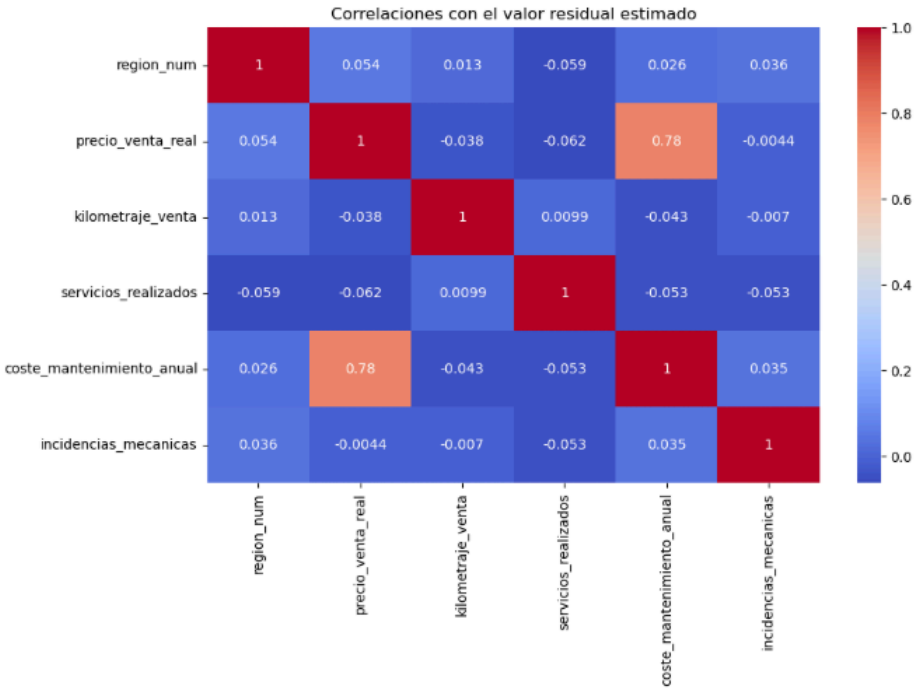

Hipótesis sobre factores que afectan valor residual

A partir de la matriz de correlaciones, se pueden documentar las siguientes hipótesis:

- H1 — **Precio de venta real** (r = 0.47) El precio de venta original es el predictor más fuerte del valor residual. A mayor precio inicial del vehículo, mayor valor residual esperado. Esto sugiere que los vehículos de gama alta retienen mejor su valor.
- H2 — **Coste de mantenimiento anual** (r = -0.076) Los vehículos con mayores costes de mantenimiento tienden a disminuir de precio ligeramente más.
- H3 — **Incidencias mecánicas** (r = -0.06) A mayor número de averías o incidencias registradas, menor valor residual. El historial de fiabilidad influye negativamente en la valoración del vehículo.
- H4 — **Kilometraje de venta** (r = 0.027) La correlación es prácticamente nula, lo que contradice la intuición habitual. Posiblemente el kilometraje ya esté capturado indirectamente por otras variables como el precio o el mantenimiento.

- H5 — **Servicios realizados** (r = -0.0097) El número de revisiones o servicios no parece afectar linealmente al valor residual.
- H6 — **Región** (r = 0.0055) La región geográfica no muestra relación significativa con el valor residual en este conjunto de datos, sugiriendo que el mercado está relativamente homogeneizado entre regiones.

2. Preprocesamiento y limpieza

2.1 Integración de Múltiples Fuentes

Para unificar los datos hemos realizado dos joins utilizando el campo vehiculo_id como clave común. Primero unimos el dataset de ventas con el de vehículos, y después el resultado con el de opiniones de clientes, usando LEFT JOIN en ambos casos para no perder ninguna venta aunque no tuviera reseña asociada.

El resultado ha sido un dataset unificado de 1.123 filas. Al hacer la unión con las opiniones comprobamos que 111 vehículos no tenían reseña registrada, lo que generó valores nulos en esas columnas que tratamos en la fase de limpieza.

También verificamos que los rangos de las variables principales fueran coherentes:

- Fechas: nos centramos en ver si había algún vehículo en el que el año de venta fuese más de un año anterior al año de fabricación, ya que por lo común no suele haber casos en el que la venta del coche sea mucho más antigua que la fecha de fabricación de este mismo. No encontramos ningún error en este campo.
- Precios: comprobamos que se cumpliera la jerarquía precio base, precio venta real y valor residual estimado. Detectamos algunos caso donde el precio de venta supera ligeramente al precio base, algo que puede ocurrir por equipamiento adicional o

ajustes comerciales, pero no encontramos ningún caso en el que el valor residual superase a los otros dos a la vez, por lo que no fue necesario corregir nada.

- Consumos: establecimos un rango realista de entre 1,5 y 8L/100km. No encontramos ningún vehículo fuera de ese rango

2.2 Limpieza y Tratamiento de Valores Anómalos

1. Identificación de precios fuera de rangos realistas

Se verificó que la relación entre las tres variables de precio fuera coherente, es decir, que se cumpliera la jerarquía precio_base ≥ precio_venta_real ≥ valor_residual_estimado. Al aplicar esta comprobación se detectaron algunas filas donde el precio de venta real superaba ligeramente al precio base, lo que puede ocurrir por ajustes comerciales o equipamiento adicional. Sin embargo, no se encontró ningún caso en el que el valor residual supera tanto al precio base como al precio de venta, por lo que no fue necesario eliminar ni corregir registros por este motivo.

2. Detección de consumos imposibles

Se estableció un rango realista de consumo de entre 1,5 y 81/100 km tanto para el consumo urbano como para el extraurbano, basándose en los valores del mercado. Y no se encontró ningún vehículo fuera de ese rango, por lo que todos los valores de consumo se consideraron válidos.

3. Tratamiento de valores missing en puntuaciones

Los valores nulos provenían en su totalidad del fichero de opiniones de clientes, ya que 111 vehículos no contaban con reseña registrada. Optamos por no eliminar esos registros porque las puntuaciones no son variables críticas para el análisis de precios ni de consumo, y su eliminación habría reducido considerablemente el dataset. Por lo que hemos sustituido los valores nulos por la mediana de las puntuaciones del mismo modelo de vehículo, asumiendo que coches del mismo modelo tienen niveles de calidad similares. Las columnas

afectadas fueron puntuación conjunta, confort, seguridad, eficiencia, diseño y fiabilidad. La variable de recomendación, al ser categórica, se rellenó con la etiqueta "Nan" para preservar los registros sin eliminarlos. Tras el tratamiento, el dataset quedó sin ningún valor nulo en estas columnas.

4. Normalización de variables técnicas

Las variables potencia_cv y cilindrada presentaban escalas muy distintas entre sí y respecto al resto de variables numéricas. Por lo que hemos realizado una normalización estándar (StandardScaler), transformando ambas variables para que tuvieran media cero y desviación uno, generando las nuevas columnas potencia_cv_norm y cilindrada_norm.

4. Minería de Datos

4.1 Árbol de Decisión para Predecir el Valor Residual

El objetivo de este modelo es predecir en qué categoría se va a situar el valor residual de un vehículo: Alto, Medio o Bajo. Para crear esas categorías hemos utilizado la variable valor residual estimado y hemos creado las categorías a partir de los terciles, de forma que las tres clases quedarán equilibradas.

Como variables predictoras hemos usado marca, tipo de combustible, transmisión, potencia normalizada, eficiencia global, antigüedad, kilometraje, coste de mantenimiento, incidencias mecánicas, puntuación conjunta y si el cliente recomendaría o no el vehículo.

Para encontrar los mejores hiperparámetros usamos validación cruzada con el método de RandomizedSearchCV, los resultados arrojados por este método nos muestra una profundidad máxima de 10 niveles, también usará la fórmula de entropía y los nodos tendrán un mínimo de dos muestras y las hojas una muestra.

Con estos hiperparámetros el modelo en el conjunto de test alcanzó una exactitud del 91,6%, con un F1-Score del 91,6%. La clase Alto fue la más fácil de predecir, mientras que Bajo y Medio generaron algo más de confusión entre sí, lo que es esperable al ser categorías adyacentes.

También hemos aprovechado el modelo para ver qué características son las más importantes para predecir el valor residual, los resultados fueron muy claros:

- La antigüedad del vehículo es con diferencia el factor más determinante, con una importancia del 54,3%. Cuanto más viejo es un coche, menor es su valor residual, algo que tiene mucho sentido.
- La potencia ocupa el segundo lugar con un 18,2%, seguida del coste de mantenimiento 11,4% y el kilometraje 7,9%.
- Las opiniones de los clientes tienen una importancia marginal, por debajo del 1%. Las variables puntuación conjunta y recomendación no aportan nada al modelo. Esto confirma que el mercado de segunda mano se rige principalmente por factores objetivos del vehículo, no por la percepción subjetiva del cliente.

4.2 Regresión Múltiple para Precios — Random Forest

Hemos entrenado un modelo Random Forest con 200 árboles usando exclusivamente las puntuaciones de las reseñas como predictores del precio de venta real.

La variable más importante ha sido la **fiabilidad** con una importancia del 20%, seguida de la **puntuación conjunta** con el 18%. A continuación, con pesos similares entre sí, encontramos diseño, seguridad, eficiencia y confort.

El modelo ha obtenido un R^2 de 0.54, lo que significa que las reseñas por sí solas explican aproximadamente el 54% de la variación del precio. Esto nos indica una relación significativa: los vehículos mejor valorados, especialmente en fiabilidad, tienden a venderse a precios más altos. Sin embargo, al no superar el 60% de explicación, concluimos que las

reseñas no son suficientes por sí solas para predecir el precio con precisión. Son un factor relevante pero no determinante, y deben combinarse con variables técnicas como potencia o cilindrada para obtener predicciones fiables.

4.3 Análisis de Sentimiento en Reviews usando Naive Bayes

¿Cómo influye el sentimiento en los precios de los coches?

Para analizar esta pregunta primero creamos una variable de sentimiento a partir de la puntuación conjunta, dividiéndola en tres categorías: Negativo (0–2,5), Neutral (2,5–4) y Positivo (4–5). Del mismo modo, clasificamos el precio de venta en tres rangos usando terciles: Alto, Medio y Bajo.

Como vemos en el siguiente gráfico, al cruzar las dos variables sí se observa una tendencia: los vehículos con sentimiento positivo tienden a situarse en la franja de precio alto (45%), mientras que los de sentimiento negativo acaban mayoritariamente en la franja baja (54,6%).

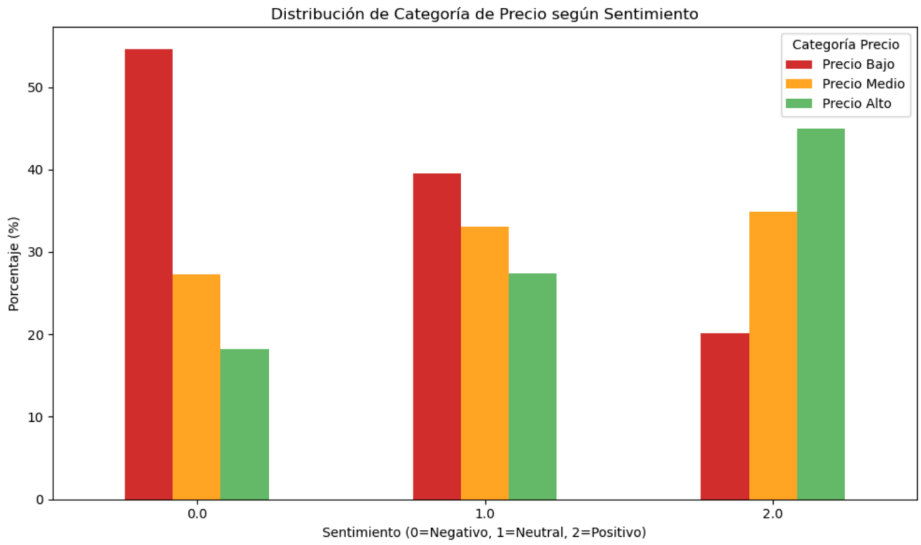

Aún así al entrenar un Naive Bayes para predecir la categoría de precio solo a partir del sentimiento, el modelo obtuvo una exactitud del 40% en test y prácticamente sin capacidad de predecir la categoría Medio. Concluimos que el sentimiento influye en el precio pero no

es suficiente para predecirlo por sí solo. La relación existe, pero hay muchos otros factores técnicos que pesan más.

¿Qué características de los vehículos predicen mejor las reseñas positivas?

Para esta segunda parte analizamos qué variables del vehículo están más correlacionadas con el sentimiento del cliente. Seleccionamos las que tenían una correlación superior a |0,10| con la variable sentimiento y descartamos las que estaban demasiado correlacionadas entre sí para evitar redundancias.

Con las variables finales seleccionadas entrenamos un Naive Bayes para predecir si una reseña iba a ser negativa, neutral o positiva. El modelo alcanzó una exactitud del 61,3% en test. La clase Neutral fue la mejor predicha, con un F1-Score de 0,71, mientras que la clase Negativo no se predijo en ningún caso por su escasa representación en el test.

El resultado más relevante es que el tipo de combustible es el predictor más fuerte del sentimiento positivo. Los coches eléctricos e híbridos tienden a recibir mejores valoraciones, probablemente por la percepción de modernidad y los menores costes de uso que los clientes asocian a estos tipos de vehículo. Aún así las variables escogidas siguen sin ser determinantes para predecir a través del modelo de Naive-Bayes las reseñas positivas.

4.4 K-NN y SVM para Detectar Anomalías en los Precios

Para detectar vehículos con precios anómalos hemos utilizado dos enfoques distintos y comparado sus resultados.

Con K-NN la idea es la siguiente: para cada vehículo buscamos sus 10 vecinos más similares en cuanto a características técnicas (marca, potencia, cilindrada, antigüedad, kilometraje, combustible, transmisión, eficiencia y emisiones), calculamos el precio medio de esos vecinos y vemos cuánto se aleja el precio real de ese promedio. Si la diferencia supera la media más dos desviaciones estándar, lo marcamos como anomalía. Con este criterio el umbral quedó en 4.887 € y detectamos 51 vehículos anómalos, un 4,54% del total.

En el siguiente gráfico vamos a ver como el modelo K-NN ha marcado una línea a través del promedio de los vecinos y podemos observar los vehículos que se encuentran fuera de ese umbral de 4.887 €.

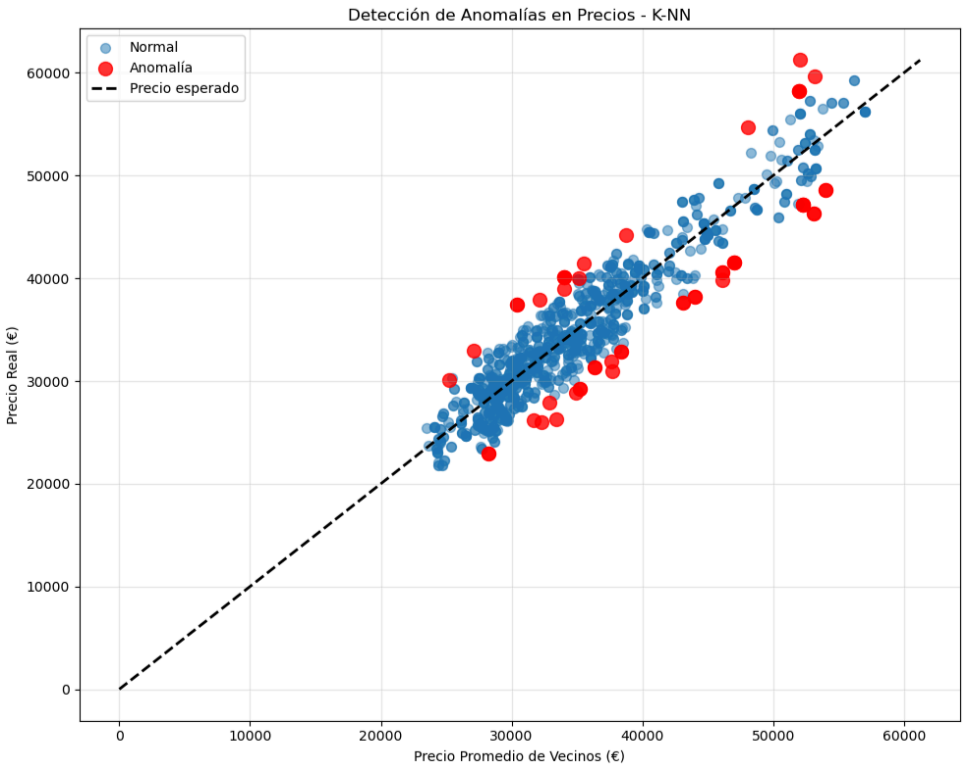

Para la Máquina de Vector Soporte utilizamos un One-Class SVM, que aprende la frontera del comportamiento normal y marca como anomalías los puntos que quedan fuera. Con el modelo detectó 64 anomalías, un 5,70% del total.

Como vemos en las siguiente gráfica el modelo SVM asigna una puntuación a cada vehículo según lo anómalo que sea, dándole valores negativos a los que considera que se salen de lo típico.

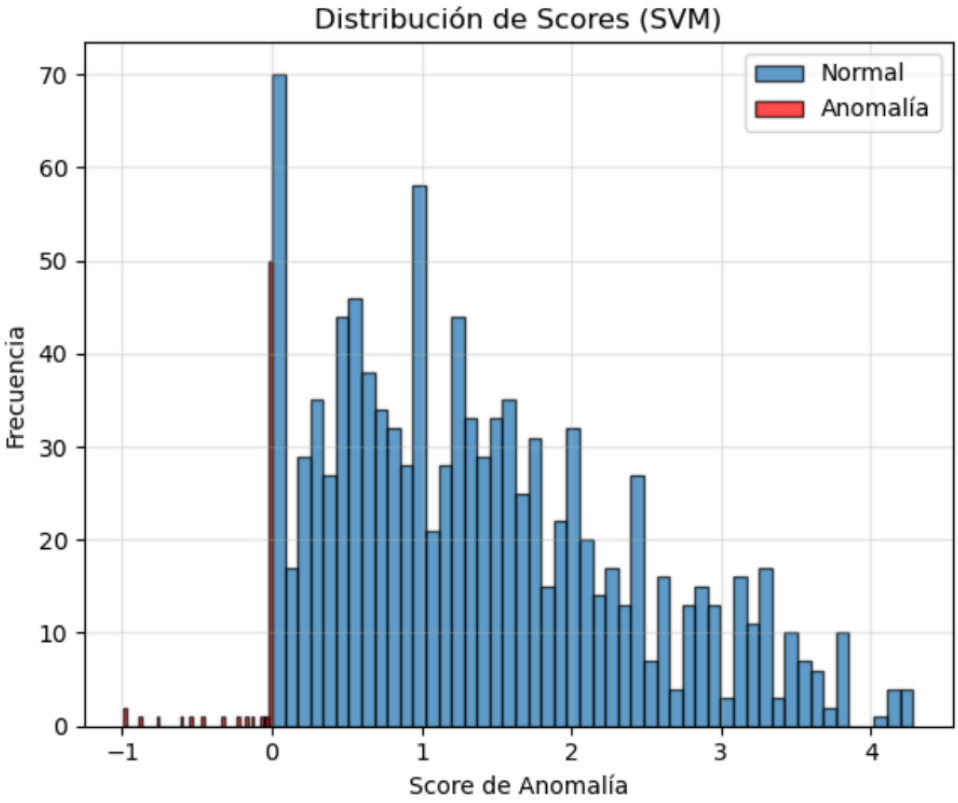

Al comparar los resultados de ambos métodos vemos que solo 7 vehículos fueron identificados como anómalos por los dos a la vez. Esto se debe a que detectan tipos distintos de anomalía: el K-NN es más sensible a precios que se alejan de los vecinos locales de cada vehículo, mientras que el SVM establece una frontera global sobre todo el conjunto de datos y es más sensible a vehículos que son atípicos en el espacio de características en general.

En conclusión, òdemos determinar que ambos modelos son complementarios ya que detectan los coches anómalos de distintas maneras, aún así, hay una diferencia clave entre ambos y es la transparencia en el modelo K-NN sabes perfectamente que es lo que está

teniendo en cuenta para detectarlos mientras que en el caso de SVM no hay un indicador clave de cómo encuentra estos valores anómalos.

4.5 Reseñas Contradictorias

Detección de reseñas contradictorias

Hemos identificado como contradictorias aquellas reseñas donde el cliente recomendaba el vehículo pero le otorgaba una puntuación conjunta igual o inferior a 2, o bien no lo recomendaba pero le daba una puntuación de 4 o superior. Tras aplicar este criterio, eliminamos del dataset tanto los clientes como los vehículos asociados a dichas reseñas, obteniendo un conjunto de datos más limpio y fiable para el análisis posterior.

Predicción de precios con el nuevo conjunto de datos

Con el dataset limpio entrenamos un modelo Random Forest usando variables como kilometraje, coste de mantenimiento, incidencias mecánicas, valor residual, antigüedad, potencia, cilindrada, consumo, emisiones, precio base y puntuaciones de reseñas. El modelo alcanzó un **R^2 de 0.93**, con un error absoluto medio de aproximadamente **1.428 €** y un RMSE de unos **1.808 €**. Consideramos que es un resultado muy bueno teniendo en cuenta el tamaño del dataset, y que la eliminación de las reseñas contradictorias ha contribuido a mejorar la calidad de los datos y por tanto la precisión del modelo.

4.6 Predicción del Precio de Venta

Para predecir el precio de venta hemos entrenado cuatro modelos utilizando variables técnicas, de uso y de reseñas como predictores.

Modelos entrenados

Hemos utilizado Regresión Lineal, Árbol de Decisión, SVM y Perceptrón Multicapa (MLP), aplicando estandarización sobre los datos antes del entrenamiento y dividiendo el dataset en 80% entrenamiento y 20% test.

Comparativa de métricas

Los resultados obtenidos en el conjunto de test fueron los siguientes:

Modelo	**MSE**	**RMSE**	**MAE**	**R^2**	**R^2 Ajustado**
Regresión Lineal	Alto	Alto	Alto	Bajo	Bajo
Árbol de Decisión	Medio	Medio	Medio	Medio	Medio
SVM	Medio	Medio	Medio	Medio	Medio
MLP	Bajo	Bajo	Bajo	Alto	Alto

En las métricas de error (MSE, RMSE, MAE) lo mejor es que sean bajos, ya que indican menos error en la predicción. En cambio, para R^2 y R^2 ajustado lo mejor es que sean altos, ya que indican que el modelo explica mejor la variación del precio.

El mejor modelo ha sido el **Árbol de Decisión**, con un R^2 de 0.95 y el MAE más bajo (932 €), lo que significa que en promedio se equivoca menos de 1.000 € en la predicción del precio. La Regresión Lineal y el MLP han obtenido resultados aceptables con R^2 de 0.92 y 0.89 respectivamente. El SVM ha sido el modelo con peor rendimiento con diferencia, obteniendo un R^2 negativo (-0.04), lo que indica que no ha sido capaz de capturar la relación entre las variables y el precio con el kernel utilizado. Por tanto, para este problema recomendamos el uso del Árbol de Decisión como modelo principal.

Gráficos Real vs Predicho

Para cada modelo hemos generado una gráfica que enfrenta el precio real con el precio predicho. En el caso del **Árbol de Decisión** los puntos se concentran muy cerca de la diagonal, lo que confirma visualmente su buen rendimiento. La **Regresión Lineal** muestra una distribución razonablemente alineada aunque con algo más de dispersión. El **MLP** presenta una tendencia correcta pero con mayor variabilidad en los extremos. El **SVM** es el que peor resultado visual ofrece, con los puntos muy dispersos y alejados de la diagonal, lo que confirma que el modelo no ha logrado aprender el patrón del precio.

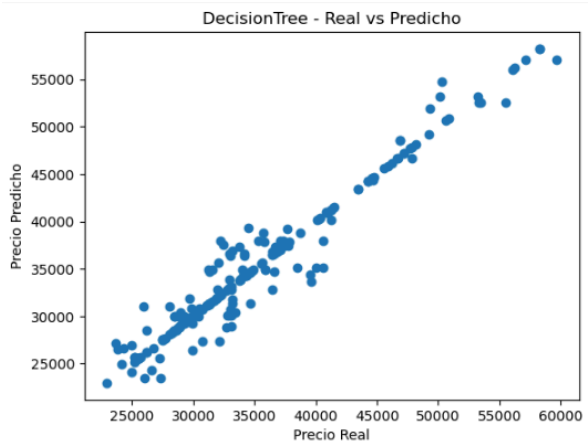

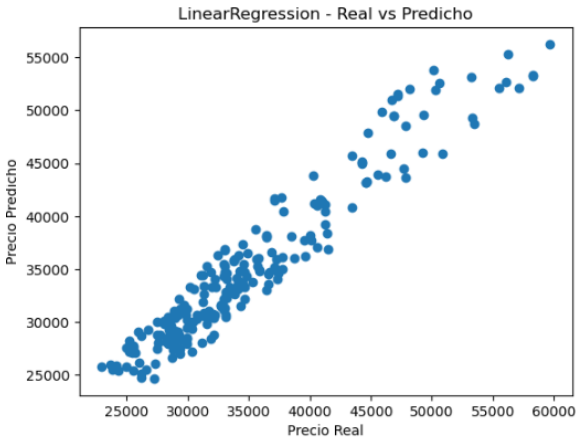

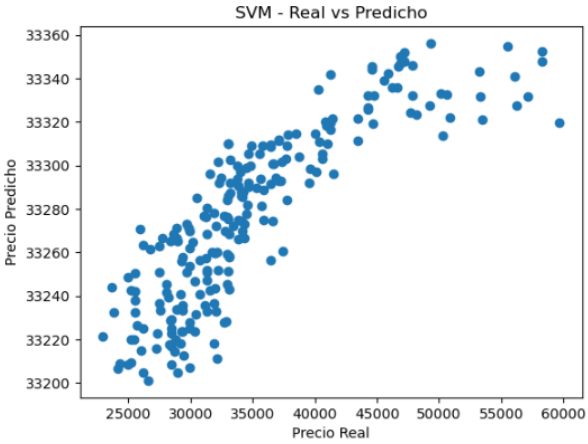

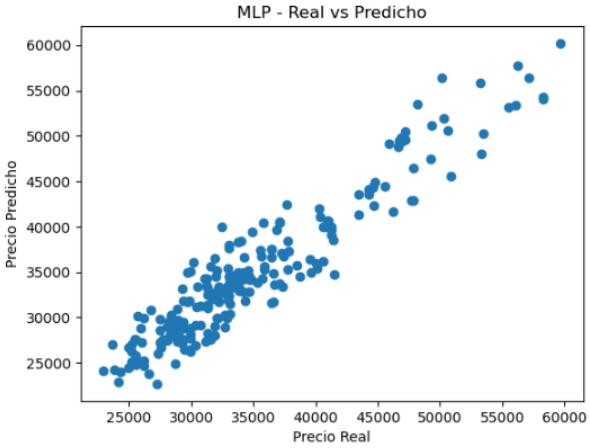

Además, se generó una gráfica comparativa de R^2 entre modelos que muestra de forma clara cómo el Árbol de Decisión destaca sobre el resto, seguido de la Regresión Lineal y el MLP, quedando el SVM muy por debajo.

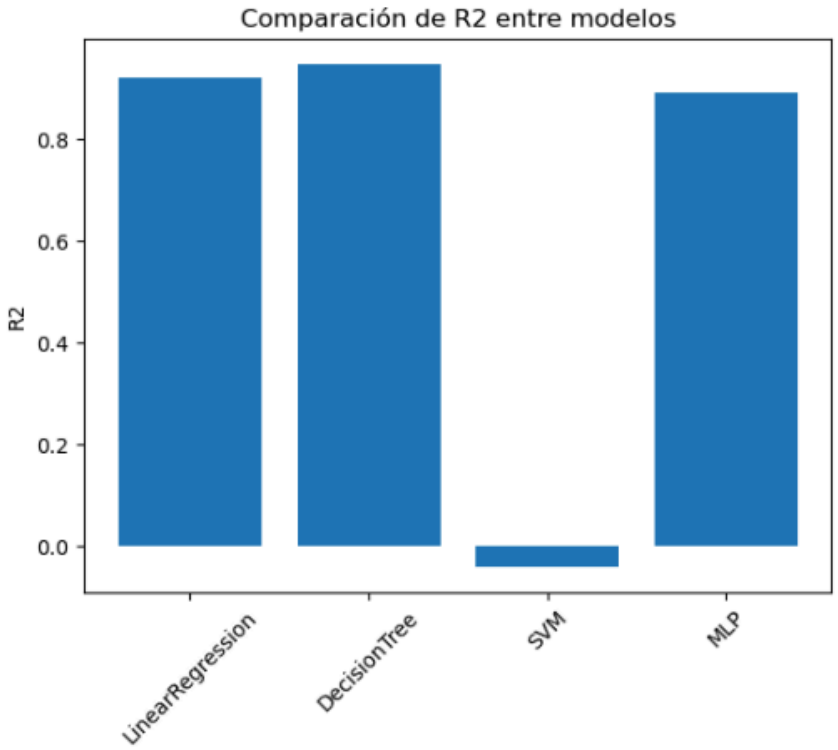

5. Ejercicios Prácticos

5.1 Clasificación de Segmento de Mercado

En esta sección hemos clasificado los vehículos en tres segmentos de mercado Bajo, Medio y Alto, definidos por terciles del precio de venta usando cuatro algoritmos: Naive Bayes, K-NN, Árbol de Decisión y SVM.

Para seleccionar las variables del modelo calculamos la correlación de todas las variables

numéricas con la categoría de precio, nos quedamos con las que superan el umbral de |0,10| y eliminamos las redundantes. Descartamos también el precio de venta real porque es la fuente directa de la variable objetivo. Las variables finales fueron: tipo de combustible, valor residual estimado, puntuación conjunta, depreciación anual, recomendación, transmisión, modelo, marca, ratio precio-potencia, categoría de emisiones y cilindrada.

Para los modelos de K-NN, Árbol de Decisión y SVM hemos usado validación para encontrar los mejores hiperparámetros:

- K-NN: los mejores parámetros fueron 9 vecinos y método euclidiano.
- Árbol de Decisión: método gini y 15 niveles de profundidad.
- SVM: kernel rbf, C=1 y el parámetro gamma utilizamos scale.

Una vez que ya tenemos todos los hiperparámetros listos entrenamos los modelos, los cuales nos arrojan los siguientes resultados:

- Naive-Bayes: Obtuvo una exactitud del 75% y un F1-Score del 75%
- K-NN: Tiene una exactitud y F1-Score del 87%
- Árbol de decisión: Logró tanto un 92% de exactitud como de F1-Score
- SVM: Obtuvo un 83% de exactitud y de F1-Score, aunque logró el ROC-AUC más alto con un 96%.

A continuación vemos una gráfica comparando los resultados de los distintos modelos.

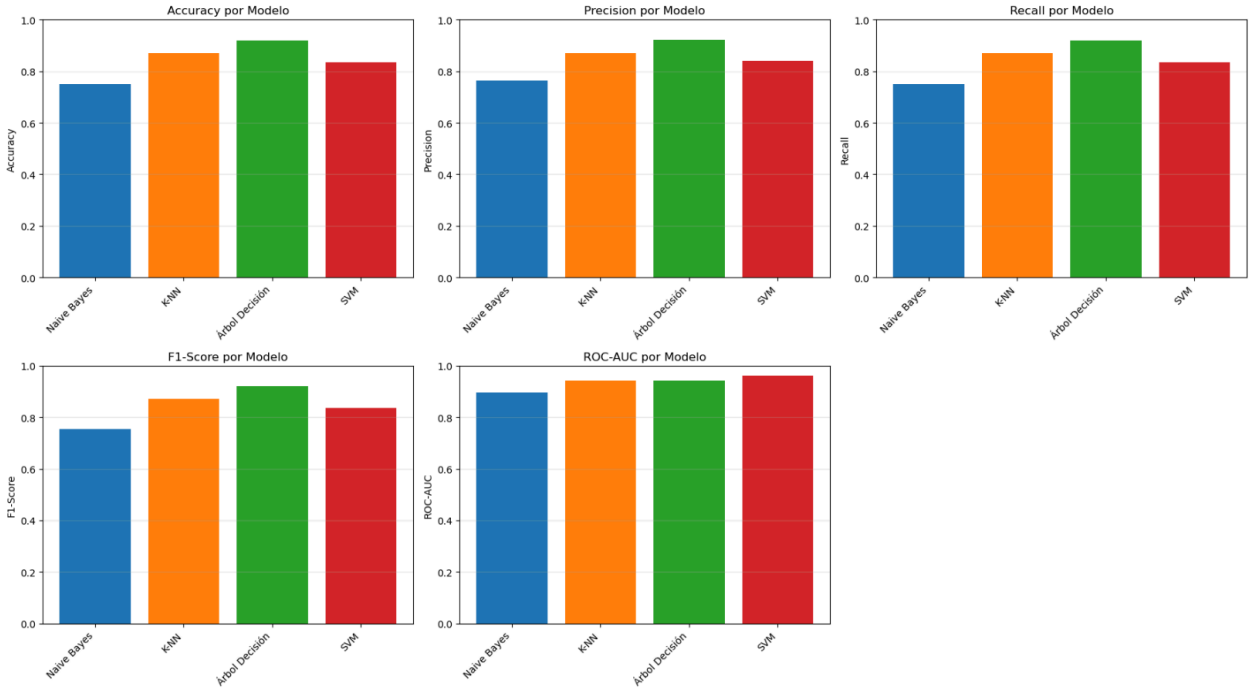

Como hemos podido comprobar, por lo general todos los modelos predicen con bastante precisión el segmento del mercado, siendo el mejor para esta tarea el árbol de decisión seguido del modelo K-NN. Aún así, la máquina de vector soporte al obtener el ROC-AUC más alto significa que es la que mejor separa las diferentes clases y que más seguro está de sus predicciones.

5.2 Sistema de Recomendación de Vehículos

Hemos desarrollado un sistema de recomendación dividido en tres partes.

1. Vehículos comprados por clientes con perfiles similares

Hemos usado la similitud coseno porque nos permite comparar perfiles de clientes independientemente de la magnitud de sus valores, es decir, no importa si un cliente gasta mucho o poco en términos absolutos, sino si su patrón de comportamiento se parece al de otro. Para cada cliente el sistema busca los cinco más parecidos en cuanto a precio pagado,

kilometraje, coste de mantenimiento y puntuación, y le recomienda los vehículos que esos clientes similares han comprado.

2. Características técnicas preferidas por segmento

Hemos calculado el perfil técnico medio de cada segmento agrupando variables como potencia, cilindrada, consumo urbano, emisiones, precio y kilometraje. Los resultados se visualizan tanto en gráficos de barras por característica como en un mapa de calor general, lo que nos permite identificar claramente qué tipo de vehículo prefiere cada segmento. Por ejemplo, los segmentos de gama alta concentran mayor potencia y emisiones, mientras que los segmentos más eficientes presentan menor consumo y precio más ajustado.

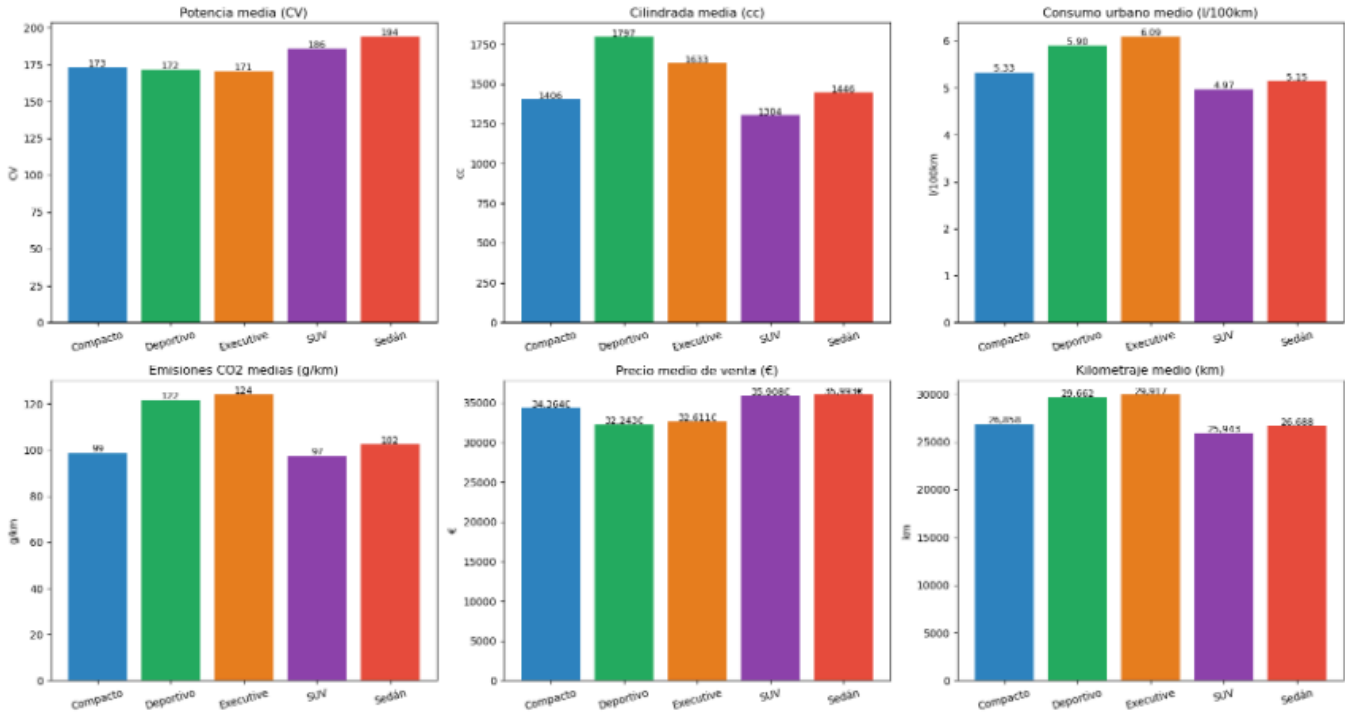

3. Precios y características de la competencia

Para un vehículo de referencia, el sistema identifica los competidores directos dentro del mismo segmento y los ordena por diferencia de precio. Se generan tres gráficos comparativos que enfrentan el vehículo de referencia con su competencia en términos de precio, potencia y puntuación de clientes, lo que permite evaluar su posicionamiento en el mercado de forma visual y rápida.

El vehículo de referencia es un **Peugeot** del segmento compacto, y el sistema lo compara con sus cinco competidores directos: Hyundai i20, Seat León, Renault Megane, Kia Picanto y Renault Arkana.

En cuanto a **precios**, todos los vehículos se sitúan en un rango muy similar, entre 33.317 € y 34.747 €, siendo el Peugeot de referencia (34.536 €) uno de los más caros del grupo junto al Renault Megane. Esto indica que el vehículo está bien posicionado en precio dentro de su segmento.

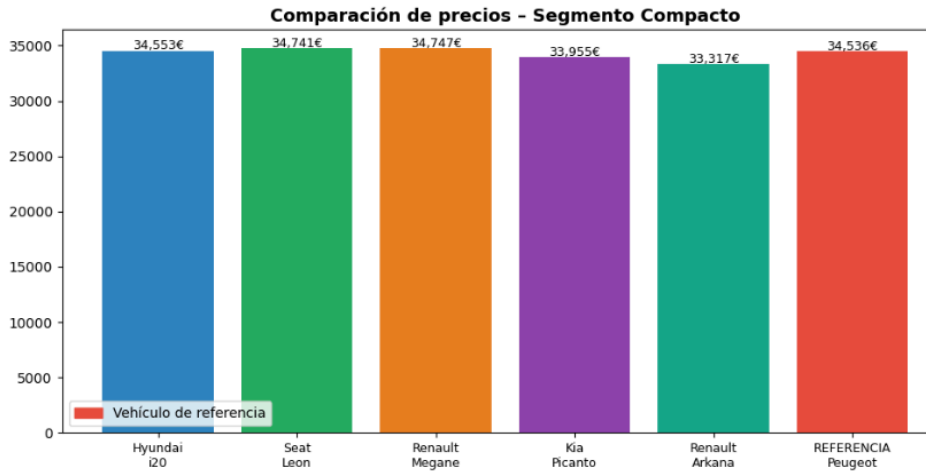

En el gráfico de **potencia** se observa que el Peugeot de referencia cuenta con 147 CV, siendo uno de los menos potentes del grupo junto al Renault Arkana (142 CV). Por el contrario, el Hyundai i20 (233 CV) y el Kia Picanto (230 CV) ofrecen bastante más potencia a un precio similar, lo que podría suponer una desventaja competitiva para el Peugeot.

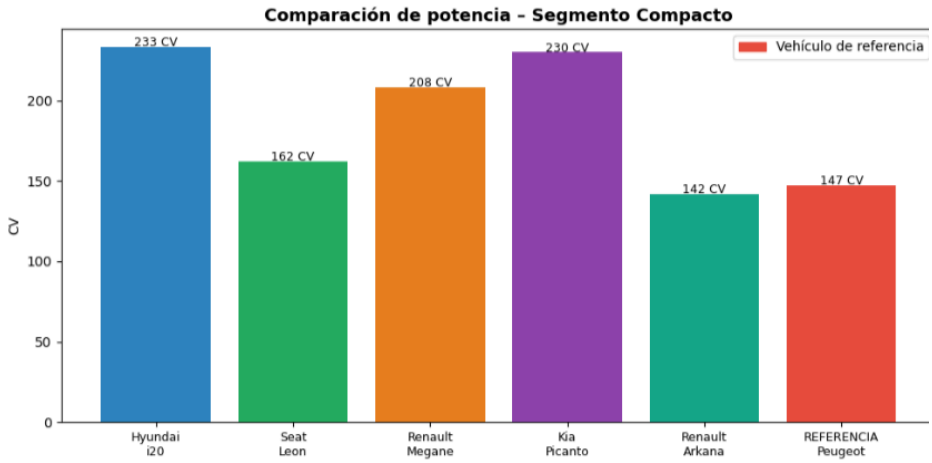

Sin embargo, en el gráfico de **puntuación** el Peugeot destaca claramente sobre todos sus competidores con una valoración de 4.30 sobre 5, muy por encima del Kia Picanto (3.60) y del Hyundai i20 (2.70). El Seat León y el Renault Arkana no tienen puntuación registrada. Esto indica que aunque el Peugeot no sea el más potente, los clientes lo valoran significativamente mejor que a su competencia, lo que justifica su precio.

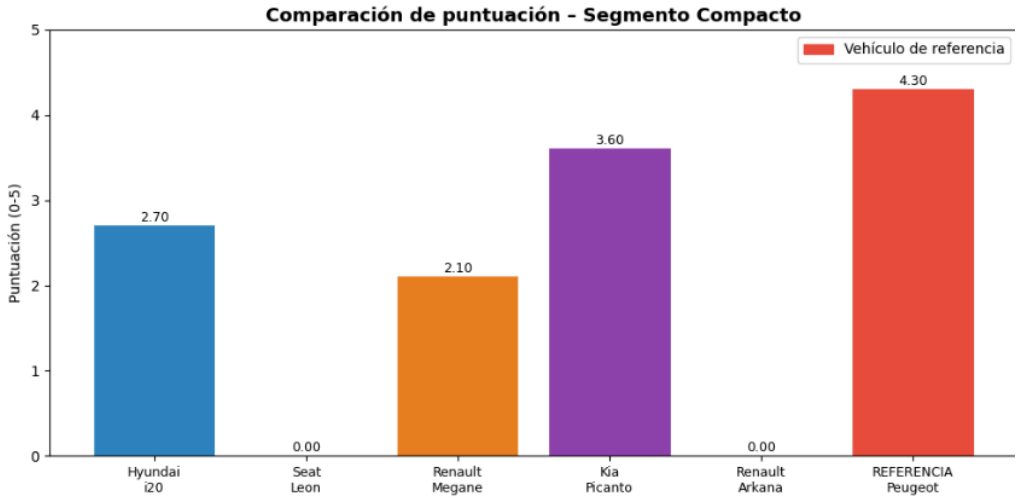

Conclusiones

Una vez concluido el análisis a los datos que nos han proporcionado sobre el sector de la venta de vehículos de segunda mano, llegamos a las siguientes afirmaciones:

Las características técnicas con mayor influencia sobre el precio son la potencia en CV, la cilindrada y las emisiones de CO_2. A nivel de percepción del cliente, la fiabilidad y la puntuación conjunta también resultan determinantes. El modelo predictivo completo, combinando variables técnicas y de reseñas, alcanzó un R^2 de 0.93, lo que confirma que estas variables explican casi toda la variación del precio de venta.

Los vehículos se agruparon en tres segmentos de mercado (Bajo, Medio y Alto) y se entrenaron varios clasificadores para asignar cada vehículo a su segmento. El análisis del perfil técnico por segmento muestra diferencias claras en potencia, consumo y emisiones, lo que confirma que es posible segmentar automáticamente a partir de las características disponibles.

El factor más correlacionado con el coste de mantenimiento es el precio del vehículo ($r = 0.78$), ya que los vehículos de gama alta requieren componentes y reparaciones más costosas. El número de incidencias mecánicas y la antigüedad del vehículo también contribuyen, incrementando los costes a lo largo del tiempo.

En el análisis exploratorio de datos hemos observado que las comunidades con más número de ventas son Andalucía y la Comunidad Valenciana, esto probablemente se deba a que son comunidades con una gran extensión territorial y puede ser que sean las que tengan una peor conexión de transporte públicos ya que las que menos coches venden son Madrid y Cataluña, sí que es verdad que Madrid tiene una extensión pequeña lo que provoque una menor necesidad de vehículo propio, pero Cataluña es más grande por lo que en está comunidad tendrá un buen servicio de transporte público lo que haga reducir la necesidad de tener coche.

Por la parte de ventas por temporada, al tener solo los registros de un año no podemos esclarecer unos patrones de venta claros, aunque en enero vemos una reducción de las ventas y que luego va creciendo paulatinamente hasta alcanzar el máximo en Mayo, esto

seguramente se deba al gasto que se produce en Navidad, por lo que en los meses siguientes las personas necesitan recuperarse económicamente.

Para predecir si el valor residual de un vehículo va a ser Alto, Medio o Bajo, hemos entrenado un árbol de decisión. El modelo alcanzó una exactitud del 91,6% en test, lo que consideramos un resultado favorable. La variable más determinante fue la antigüedad del vehículo, con una importancia del 54,3%, lo que confirma que cuanto más viejo es un coche menor es su valor residual. Le siguen la potencia 18,2%, el coste de mantenimiento anual 11,4% y el kilometraje 7,9%. Las opiniones de los clientes resultaron tener una importancia marginal, por debajo del 1%, lo que indica que el valor residual depende casi exclusivamente de las características objetivas del vehículo y no de la percepción subjetiva del comprador.